

모델 실험에서 운영 판단까지

01

Microsoft Foundry에서 모델·에이전트·도구와 평가를 함께 이해합니다.

01 역할을 구분합니다

모델, 에이전트, 도구가 각각 무엇을 담당하는지 살펴봅니다.

02 구현 경로를 고릅니다

직접 호출부터 코드 기반 에이전트까지 필요한 제어 수준으로 선택합니다.

03 근거로 출시를 판단합니다

평가 결과와 실패 사례, 운영 책임을 연결해 진행 여부를 결정합니다.

출발점

좋은 답변 한 번보다 반복 가능한 업무 결과가 중요합니다. 해결할 문제와 허용할 행동부터 정합니다.

읽는 방향

기능을 고르기 전에 업무 범위, 통제 조건, 출시 근거를 연결합니다.

범위

Azure AI Foundry의 현재 브랜드는 Microsoft Foundry입니다. 모든 기능이 모든 리전에 제공되는 것은 아닙니다.

좋은 시연과 운영 준비는 다릅니다

같은 AI 응답도 실험과 업무 운영에서는 확인해야 할 조건이 달라집니다.

01

실험 · 가능한가

짧은 입력으로 모델의 응답을 살펴보고 업무 가설을 좁힙니다.

전환의 이유

실험은 가능성을 찾는 출발점입니다.
대표 사례 하나가 전체 사용자와 예외 상황을 대신하지는 않습니다.



02

운영 · 맡길 수 있는가

대표 질문과 실패 조건, 허용 행동, 관측과 중단 책임을 함께 확인합니다.

선택 기준


실험을 버리는 대신 평가 데이터, 접근 통제, 추적 기록을 더해 반복 가능한 판단으로 발전시킵니다.

주의할 해석

아래 비교는 도입 관점의 제안입니다. Foundry를 선택했다는 사실만으로 운영 준비가 끝나지는 않습니다.


Foundry의 역할을 세 층으로 읽습니다

입력과 모델·도구, 에이전트 구성, 업무 응용을 잇는 개념도입니다.



평가 기준부터 작은 실행을 연결합니다

범위 → 구현 → 평가 → 운영 준비로 이어지는 네 단계 도입 제안입니다.



필요한 제어 수준으로 구현을 고릅니다

직접 모델 호출, prompt agent, hosted agent는 서로 다른 시작점입니다.

시작 경로	직접 관리하는 것	선택 기준
모델 직접 호출	애플리케이션 코드	도구 없이 추론이 필요
Prompt agent	지침 · 모델 · 도구	선언형 구성으로 시작
Hosted agent	자체 코드와 의존성	고유한 실행 로직 제어

판단의 중심



도구가 필요하지 않다면 직접 호출부터 검토합니다. 고유한 코드가 필요한 경우에만 복잡도를 늘립니다.

비교의 전제

비교는 텍스트 중심 업무 범위입니다. 음성 기반 prompt agent는 이번 표에서 제외합니다.

해석의 한계

직접 호출은 에이전트 유형이 아닙니다. 실제 지원 모델·도구·리전과 출시 상태를 별도로 확인합니다.

사내 문서 Q&A는 근거부터 확인합니다

질문, 접근 확인, 근거 검토, 답변을 잇는 가상 업무 시나리오입니다.

01 사용자 · 질문

업무 맥락과 필요한 답변을 제공하며 민감한 입력을 최소화합니다.

04 사용자 · 답변 확인

답변과 근거를 검토하고 불확실한 내용은 담당자에게 넘깁니다.

02 응용 · 접근 확인

신원과 허용 자료 범위를 확인한 뒤 검색 요청을 구성합니다.

03 에이전트 · 근거 검토

검색된 자료가 질문에 답하는지 확인하고 출처를 연결합니다.

장면의 연결

직원이 허용된 사내 문서를 질문합니다. 확인할 근거가 없으면 답을 꾸며내지 않고 추가 확인을 요청합니다.

인계의 품질

단계 사이에는 질문만 아니라 접근 범위와 근거가 함께 전달되어야 합니다.

예외의 처리

검색·권한·거부 처리는 설계 요구사항입니다. 이 그림이 제품의 자동 차단을 보장하지 않습니다.

출시 전 네 가지 근거를 확인합니다

체크 기호는 검토 대상이지 실제 승인이나 충족 상태가 아닙니다.

☐ **업무 적합성** 대표 질문과 실패 사례에서 원하는 결과를 설명할 수 있습니까?

☐ **접근과 허용 행동** 누가 어떤 자료와 도구를 사용할 수 있는지 검증했습니까?

☐ **기능별 준비 상태** GA/Preview, 대상 리전과 모델·도구 조건을 확인했습니까?

☐ **운영과 중단 책임** 오류·비용·기록을 확인하고 필요하면 중단할 담당자가 있습니까?

검토 방식

기능·모델·도구 또는 데이터 범위가 바뀌면 같은 질문으로 다시 검토합니다.

통과의 의미

필수 조건을 뒷받침할 기록이 있을 때 제한된 적용을 검토합니다.

보류의 가치

미확인 조건은 완료로 표시하지 않습니다. 책임자와 다음 확인 시점을 남깁니다.

공식 상태와 도입 판단을 분리합니다

포털의 GA와 개별 기능의 GA는 같은 범위가 아닙니다.



근거의 범위

공식 GA 개요를 2026-09-30에 확인했습니다. 상태는 이후 바뀔 수 있습니다.

01

Agents 핵심 기능 · GA

에이전트의 세부 유형, 연결 도구와 모델 조건까지 한꺼번에 보장하는 표기는 아닙니다.

02

Evaluations · GA / 일부 Preview

평가 기능 안에서도 평가자와 세부 기능의 출시 상태를 나눠 확인합니다.

03

Monitoring · Memory · Preview

운영 적용 정책과 데이터 보관·사용 조건을 기능별로 검토합니다.

해석

기능별 상태를 기록한 다음 업무 검증, 대상 리전과 운영 조건을 별도로 판단합니다.

한계

GA는 모든 하위 기능·모델·리전의 보장이 아닙니다. 실제 채택 시 최신 표를 다시 확인합니다.

일정보다 단계별 통과 조건을 정합니다

탐색, 제한 검증, 운영 준비의 산출물을 연결하는 도입 로드맵 제안입니다.

실행 묶음	준비	실행	검토
탐색 · 업무 가설	문제 정의, 대표 질문, 제외 조건과 기대 결과를 문서로 남깁니다.		
검증 · 실패 근거		제한된 데이터로 구현하고 평가 기록·권한 시험·수정 이력을 남깁니다.	
준비 · 운영 책임	관측, 오류 대응, 비용 확인과 중단 계획을 합의합니다.		

단계의 의미

날짜와 소요 기간을 보장하지 않습니다. 업무 난도와 데이터·권한 준비 상태에 따라 달라집니다.

이어지는 책임


다음 단계로 넘어갈 때 이전 단계의 실패 사례와 가정을 함께 넘깁니다.

계획의 한계

질문·데이터 범위가 달라지면 검증을 다시 설계합니다. 작은 시연만으로 확대 적용하지 않습니다.

허용 문서를 검색 근거로 연결합니다

문서 → 정제 → 검색 자료 → 답변·검토로 분기하는 가상 데이터 흐름입니다.



—— 실선 = 데이터 전달

가상 설계 · 배포 아님

변환

문서 식별자와 접근 범위를 유지하며 조각을 준비합니다. 형식 오류와 권한 검사는 별도 설계합니다.

분기


답변에는 관련 근거를, 평가에는 검토 기록을 연결합니다. 저장했다고 답변 품질이 보장되지는 않습니다.

가정

실선은 제안한 데이터 전달입니다. 실제 Foundry 내부 구조나 자동 수집·동기화를 뜻하지 않습니다.

검색 요청과 근거 반환을 구분합니다

응용 → 에이전트 → 검색 도구의 정상 경로를 단순화한 가상 시퀀스입니다.



순서

응용은 질문을 보내고 에이전트는 도구로 근거를 요청합니다. 도구는 허용된 검색 결과를 반환합니다.

책임

검색 근거를 받은 뒤 답변을 구성합니다. 세로 간격과 화살표 길이는 지연 시간을 뜻하지 않습니다.

범위

실제 모델 호출·추가 도구·승인·오류·재시도는 생략했습니다. 특정 SDK 호출 순서를 보장하지 않습니다.

접근 경로와 작업 권한은 별개입니다

Q&A 응용의 가상 접근 경계입니다. 실제 Azure 배포도나 사설 연결 보장이 아닙니다.



경계

사용자, 진입점, 업무 응용과 문서 자료를 논리적 구역으로 나눴습니다.

ID와 정책

경로가 열려 있어도 신원과 작업 권한은 따로 확인합니다. 관리 경로와 정책 전파는 생략했습니다.


검증 전 설계

차단 표시는 의도입니다. 실제 네트워크·RBAC·데이터 접근 설정과 시험으로 검증해야 합니다.

평가 차트는 단위와 표본부터 읽습니다

가상 검토 건수 40·65·85건을 0~100건 축에 표시합니다. 실측 성능이 아닙니다.

가상 예시 · 실측 아님



차트와 같은 값 · 단위: 건

질문 세트	검토 건수
세트 A	40건
세트 B	65건
세트 C	85건

정의 / 검토 건수

차트 정의는 검토한 질문 수입입니다. 정답률, 처리 속도나 비용 절감률이 아닙니다.

해석 / 규모 차이

표본 C의 수가 더 많아도 품질 우위를 뜻하지 않습니다. 시간·입력량·질문 구성을 함께 봅니다.

표본 / 실측 아님

레이아웃 설명용 가상 데이터입니다. 실제 평가·고객 성과·모델 벤치마크로 인용하지 않습니다.

근거 확인 지점을 코드로 설명합니다

권한, 검색, 근거 부족 시 행동을 읽는 의사 코드입니다. 실행 가능한 SDK 예제가 아닙니다.

예시 의사 코드 · 실행 불가 / 제품 화면 아님

```
01 INPUT question, user
02 scope = authorize(user)
03 evidence = search(question, scope)
04 IF empty(evidence): ASK HUMAN
05 answer = compose(question, evidence)
06 record_refs(answer, evidence)
07 RETURN answer
```

2 02행 · 권한 확인

2행은 허용 자료 범위를 확인하는 설계 지점입니다. 모델 지침만으로 권한을 통제하지 않습니다.

4 04행 · 근거 부족

4행은 근거가 없을 때 추가 확인을 요청하는 분기입니다. 빈 결과를 성공으로 숨기지 않습니다.

6 06행 · 참조 기록

6행은 근거와 응답 기록을 연결하는 지점입니다. 민감한 원문은 무조건 기록하지 않습니다.

범위

2행은 허용 자료 범위를 확인하는 설계 지점입니다. 모델 지침만으로 권한을 통제하지 않습니다.

판단

4행은 근거가 없을 때 추가 확인을 요청하는 분기입니다. 빈 결과를 성공으로 숨기지 않습니다.

원본 교체

6행은 근거와 응답 기록을 연결하는 지점입니다. 민감한 원문은 무조건 기록하지 않습니다.

작은 업무와 명확한 출시 근거를 남깁니다



Foundry 도입은 기능 목록보다 업무·통제·검증을 연결하는 일입니다.

이제 정할 것

모델과 도구, 에이전트의 역할을 구분한 뒤 필요한 구현 범위를 선택합니다.

01 첫 업무를 고릅니다

질문·데이터·허용 행동이 명확한 사례 하나로 범위를 좁힙니다.

02 필요한 증거를 정합니다

대표 질문, 실패 조건과 출시·보류 기준을 합의합니다.

03 검토 책임을 연결합니다

담당자, 남은 질문과 다음 확인 시점을 기록합니다.

남길 합의

작게 시작하되 접근 조건과 평가 기록, 운영 책임은 처음부터 함께 설계합니다.

남길 질문

미확인 기능·리전·비용과 남은 실패 사례를 숨기지 않습니다. 이 자료는 실제 배포 보고서가 아닙니다.